

Srčana varijabilnost. Analiza patologije na osnovu Poincare dijagrama.

Elektrotehnički fakultet, Univerzitet u Sarajevu

Sarajevo, Bosna i Hercegovina

Seminarski rad iz predmeta Biomedicinski signali i sistemi

Profesor: prof. dr Dušanka Bošković

Asistent: Mr. dipl. ing. Amina Tihak

Student: Berina Biberović

Sažetak—Ovaj rad analizira šta je srčana varijabilnost, te različite načine predstavljanja srčane varijabilnosti kroz Poincare i Bland-Altman dijagram. Nakon toga se navode različiti načini kako se patološki slučajevi mogu detektovati kroz Poincare dijagram, kao i koje su razlike na Poincare dijagramima zdravih pacijenata. Na kraju rada je prikazan algoritam koji ekstrahuje konture Poincare dijagrama i dat je prijedlog kako bi se tako ekstrahovane konture mogle iskoristiti za dalju klasifikaciju Poincare dijagrama na automatizirani način.

Ključne riječi—Srčana varijabilnost, Poincare dijagram, Bland-Altman dijagram, OpenCV, izdvajanje kontura

I. TIPOVI DIJAGRAMA ZA GRAFIČKO PREDSTAVLJANJE SRČANE VARIJABILNOSTI

A. Srčana varijabilnost

Srčana varijabilnost (eng. *heart rate variability*) predstavlja fiziološki fenomen varijacije vremenskih intervala između otkucaja srca. Mjeri se preko varijacije u otkucaj-otkucaj (eng. *beat-to-beat*) intervalima.

Često se unutar kliničkih ispitivanja postavlja pitanje koliko je potrebno da traje snimanje otkucaja srca tako da bi dobiveni podaci bili korisni za dalju analizu. Snimanje varijabilnosti otkucaja srca može biti u trajanju od 1 minute do preko 24 sata. U zavisnosti od toga šta je cilj studije, koriste se snimci različitih dužina. Takve snimke možemo klasificirati u tri kategorije: veoma dugi snimci, kratki i ultra kratki snimci.

Veoma dugi snimci (≥ 24 sata) predstavljaju referentni standard za kliničku evaluaciju zbog njihove prediktivne validnosti - tj. mogućnosti da predvide buduće ishode[1]. Npr. 24-satna mjerenja standardne devijacije unutar otkucajnih intervala normalnih sinusnih ritmova (SDNN) predviđaju srčani rizik. U [1] se navodi da iako dugi (≥ 24 sata), kratki (oko 5 minuta) i ultra kratki (< 5 minuta) snimci računaju HRV (eng. *heart rate variability*) metrike koristeći iste matematičke formule, oni se ne smiju miješati i upoređivati međusobno jer predstavljaju različite fiziološke procese i imaju drugačije prediktivne moći.

B. Poincare dijagram

Poincare dijagram je tip tzv. ponavljajućeg dijagrama¹ koji se koristi da bi se kvantificirala samosličnost² nekog procesa, najčešće periodičnih funkcija.

Najčešću primjenu Poincare dijagram ima u biomedicini gdje se koristi kako bi se prikazali R-R intervali srčanih otkucaja pomjereni jedan od drugog u vremenu za jedan otkucaj. U nastavku će biti više rečeno o dužini snimaka EKG signala koji se mogu koristiti za formiranje Poincare dijagrama. Primjer jednog Poincare dijagrama je prikazan na slici 1.


U zavisnosti od toga koja osobina srčanog ritma se želi proučavati, moguće je koristiti EKG snimke različite dužine. Npr. u [2] su korišteni snimci EKG signala trajanja od 5 minuta i tu autori ističu da se srčana asimetrija može uočiti u takvim snimcima iako oni traju 5 minuta (ovdje treba istaći da se ova studija radila nad zdravim odraslim osobama dok su one bile u mirovanju).

Ipak, izgleda da toliko kratki snimci nisu uobičajena praksa - mišljenje autora ovog teksta je da je to upravo zbog stohastičnih osobina snimaka srčanih ritmova. Veći broj uzoraka znači bolji opis ponašanja srčanog ritma tj. bolje određivanje raspodjele kojoj srčani ritam pripada kao i drugih osobina koje se često koriste pri analizi varijabilnosti srčanog ritma (kao što su npr. SDRR, SDSD, autokorelacija i autokovarijansa). Naročito je važno imati duže snimke pri analiziranju atipičnih srčanih ritmova (kada se radi o nekoj patologiji), jer se često u tim slučajevima u određenim intervalima pojavljuje neobično ponašanje srčanog ritma koje se možda ne bi moglo uočiti prilikom kratkog snimka od 5 minuta.


Što se tiče primjera istraživanja na ovu temu, autor ovog teksta bi izdvojio dva rada: [3] - rad koji koristi EKG snimke trajanja od 10 minuta, i [4] - rad koji koristi EKG snimke trajanja 24 sata. Oba rada pokazuju da se može izvući mnogo osobina iz snimaka odgovarajućih trajanja.

¹Ponavljajući dijagrami (eng. *recurrence plots*) u statistici su dijagrami koji prikazuju, za svaki moment i u vremenu, vremena gdje se stanje dinamičkog sistema vraća u prethodno stanje u i , tj. kada trajektorija faznog prostora posjećuje ugrubo istu površinu u faznom prostoru kao vrijeme j .

²Samoslični objekat je objekat koji je tačno ili približno sličan dijelu sebe tj. cijeli objekat ima oblik kao jedan ili više dijelova.



Slika 1. Poincare dijagram za normalni srčani ritam - MIT-BIH baza podataka, snimak broj 19140[8]



Slika 2. Poincare dijagram za aritmiju - MIT-BIH baza podataka, snimak broj 202[8]

C. Bland-Altman dijagram

Bland-Altman dijagram (ili drugim imenom *Tukey mean-difference plot*) je dijagram gdje na y osi upisujemo razliku $y_i - x_i$, dok na x osi upisujemo srednju aritmetičku vrijednost $\frac{y_i + x_i}{2}$, gdje su x_i i y_i tačke koje su uzete iz tzv. *Q-Q* dijagrama tj. *quantile-quantile* dijagrama; to je dijagram koji omogućava upoređivanje dvije distribucije - odgovarajući tzv. kvantili (eng. *quantiles*) obje distribucije se upoređuju[5].


Konkretno za srčani ritam - može se koristiti plotanje srednje vrijednosti RR intervala i PP intervala na x osi, a na y osi se može plotati njihova razlika. Primjer ovakvog načina korištenja Bland-Altman dijagrama je dat u [6]. U ovom istraživanju nije rečeno koje dužine su snimci koji su prikupljeni, ali jeste rečeno da su snimali otkucaje srca djeci koja imaju problema sa disanjem u toku spavanja - gdje su se pod subjektima koji imaju problema sa spavanjem smatrali oni koji imaju preko 5 apneja ili hipopneja u toku jednog sata spavanja.

II. DETEKCIJA PATOLOGIJE NA OSNOVU POINCARE DIJAGRAMA

Varijabilnost otkucaja srca daje neinvazivnu indikaciju tona autonomnog nervnog sistema. Poincare dijagram, u tom kontekstu, nam može otkriti mnogo o pacijentu i o njegovom stanju. U [7] autori objašnjavaju da se mogu uočiti jasne razlike između zdravih pacijenata i pacijenata koji imaju srčanu insuficijenciju. U nastavku će biti objašnjenje te razlike.

Kako autori u [7] objašnjavaju, zdravi pacijenti imaju Poincare dijagram koji izgleda kao kometa. Na slici 1 je prikazan primjer Poincare dijagrama za pacijenta koji ima zdravo srce. Vidimo jasno spomenuti oblik komete na datoj slici.

Ukoliko pacijent ima srčanu insuficijenciju, onda Poincare dijagram kod takvog pacijenta ima tri različite forme koje se mogu opisati kao: izgled torpeda, izgled lepeze i kompleksni izgled[7]. Primjer kompleksnog izgleda je dat na slici 2, primjer izgleda lepeze je prikazan na slici 3 i primjer izgleda torpeda je prikazan na slici 4.




Slika 3. Poincare dijagram sa izgledom lepeze. Slika je preuzeta iz [7].

U grupi zdravih pacijenata, srčana varijabilnost se povećava kako se R-R intervali produžavaju, što kreira specifični izgled komete - ovaj šablon (tj. izgled dijagrama) je konsistentan u svim analizama srčane varijabilnosti na koje je autor ovog teksta naišao. Kod pacijenata koji imaju neki tip srčane insuficijence se javljaju gore navedena tri tipa dijagrama konsistentno.

Torpedo izgled nije indikacija konsistentnog srčanog ritma nego je indikacija srčanog ritma koji se mijenja postepeno, a održava malu varijabilnost otkucaja. Kod druga dva distinktna izgleda dijagrama za pacijente sa srčanom insuficijencijom ukupni opseg R-R intervala je bio smanjen, ali disperzija R-R intervala je obično mnogo veća nego kod zdravih pacijenata.

Mehanizmi koji prouzrokuju ovako različite izgleda dijagrama nisu u potpunosti jasni. Više faktora može uticati na tako različite konfiguracije R-R intervala. Pacijenti koji



Slika 4. Poincare dijagram sa izgledom torpeda. Slika je preuzeta iz [7].

imaju neki tip srčane insuficijencije imaju simpatetičku pre-tjeranu aktivnost, parasimpatetičku aktivnost koja je reducirana i depresivni baroreceptorski odziv[9]. Inače, visoka simpatetička aktivnost je veoma jak pokazatelj male šanse za preživljavanjem[9].

Poincare dijagram može biti dobar alat za testiranje kompleksnih veza između simpatetičke i parasimpatetičke aktivnosti. U nastavku ćemo predstaviti jednu ideju za algoritam koji bi mogao da razvrstava Poincare dijagrame premo gore navedena 4 tipa.

III. ALGORITAM ZA DETEKTOVANJE JEDINSTVENIH OBLIKA POINCARE DIJAGRAMA

Ideja sljedećeg algoritma je da se izdvoje tačke Poincare dijagrama i da se od njih izdvoje tzv. konture sa dijagrama. Ovo je implementirano u OpenCV-u, zato što je OpenCV vodeći alat u obradi slike.


Razlog zašto se uzela obrada slike umjesto analize statističkih parametara je što se već u literaturi dosta sreće analiza statističkih parametara kod Poincare dijagrama, ali autor ovog teksta nije mogao naći nešto što analizira oblik Poincare dijagrama (osim naravno ručne analize oblika dijagrama) i na osnovu toga izdvaja neke zaključke.

U nastavku je prikazan kod koji učitava Poincare dijagram kao sliku u C++ programu koji koristi OpenCV, radi odgovarajuće pretvorbe slike koje će biti objašnjene, izdvaja konture dobivenog oblika sa slike, crta te konture u novu sliku i sprema ih na disk.

```
1 #include <opencv4/opencv2/opencv.hpp>
2 #include <opencv4/opencv2/imgproc.hpp>
3 #include <opencv4/opencv2/highgui.hpp>
4 #include <opencv4/opencv2/core/mat.hpp>
5 #include <opencv4/opencv2/imgcodecs.hpp>
6 #include <opencv4/opencv2/core/matx.hpp>
7 #include <vector>
8
```

```
9 void IzdvojiKonture(cv::Mat &slika,
10 std::vector<std::vector<cv::Point>>
11 &konture, cv::Mat &rezultat) {
12
13     // Pronalazak kontura:
14     cv::findContours(slika, konture,
15         cv::RETR_LIST, cv::CHAIN_APPROX_SIMPLE);
16
17     // Crtanje kontura:
18     for(int i = 0; i < konture.size(); i++)
19         cv::drawContours(rezultat, konture, i,
20             cv::Scalar(0, 0, 255), 2);
21 }
22
23 int main() {
24
25     // Ucitavanje slike:
26     cv::Mat slika = cv::imread("../19140.png",
27         cv::IMREAD_GRAYSCALE);
28
29     // Pretvaranje u binarnu sliku:
30     cv::threshold(slika, slika, 0, 255,
31         cv::THRESH_BINARY_INV +
32         cv::THRESH_OTSU);
33
34     // Potrebno je sliku dilatirati tako da
35     // dobijemo bolji rezultat:
36     cv::Mat element =
37         cv::getStructuringElement(
38             cv::MORPH_ELLIPSE, cv::Size(2 * 5 + 1,
39                 2 * 5 + 1), cv::Point(5, 5));
40     cv::dilate(slika, slika, element);
41
42     // Vektor u koji ćemo smjestiti konture:
43     std::vector<std::vector<cv::Point>> konture;
44
45     // Slika koja predstavlja rezultat
46     // pronalaska konture:
47     cv::Mat rezultat =
48         cv::imread("../19140.png",
49             cv::IMREAD_COLOR);
50
51     // Pretvaranje svakog piksela u bijeli na
52     // rezultantskoj slici:
53     for(int i = 0; i < rezultat.rows; i++)
54         for(int j = 0; j < rezultat.cols; j++)
55             for(int k = 0; k <
56                 rezultat.channels(); k++)
57                 rezultat.at<cv::Vec3b>(i, j)[k]
58                     =
59                     cv::saturate_cast<uchar>(255);
60
61     // Pozivanje funkcije izdvoji konture:
62     IzdvojiKonture(slika, konture, rezultat);
63
64     // Spasavanje rezultantske slike na disk:
65     cv::imwrite("../rezultat_19140.png",
66         rezultat);
67
68     return 0;
69 }
```

Bitno je naglasiti da je u prethodnom programu prvo bilo potrebno urediti ulaznu sliku Poincare dijagrama. Npr. prethodno pokazani dijagram na slici 1 je uređen na način da se maknu x i y ose sa dijagrama, kao i $grid$. Pored toga, umjesto praznih tačaka unutar *scatter plot*-a, stavljeno je da su one popunjene, tako da navedena slika sada izgleda kako je prikazano na slici 5.



Slika 5. Alternativni Poincare dijagram za normalni srčani ritam - MIT-BIH baza podataka, snimak broj 19140[8]


Nakon što je to urađeno, onda se slika može učitati u program (linija 23). Potrebno je sliku učitati kao *grayscale* da bi uopšte bilo moguće izdvojiti konture. Nakon toga je potrebno *grayscale* sliku pretvoriti u binarnu (binarne slike su slike koje prikazuju samo vrijednost 0 ili 1 na sebi, dakle samo crnu i bijelu boju), što je urađeno linijom 26.

Nakon toga, dobivena slika je binarna. Sada je potrebno uraditi jednu tzv. morfološku transformaciju dobivene binarne slike koja se zove dilatacija. Dilatacija, ukratko, radi širenje elemenata na binarnoj slici. Za to je bilo potrebno napraviti odgovarajući tzv. strukturni element koji služi da opiše kolika je veličina širenja elemenata na slici. To je sve urađeno u linijama 29 i 30. Da bi bila određena veličina strukturnog elementa, uzeto je u obzir kolike su prikazane tačkice unutar *scatter plot*-a.

Sada je potrebno učitati ponovo sliku, ali sada u boji (kako bi rezultat mogao biti u boji - linija 36). Kako želimo nacrtati konturu na ovoj rezultantskoj slici, onda sve piksele na slici pretvorimo u bijele piksele (linije 39 do 43). Nakon toga možemo pozvati korisnički definiranu funkciju `IzdvojiKonture` koja prima kao parametre binarnu sliku, vektor vektora tačaka (`std::vector<std::vector<cv::Point>>`) u koji će biti smještene izvađene konture i rezultantska izlazna slika. Svi parametri su proslijeđeni u funkciju preko reference kako bi se izbjeglo kopiranje varijabli i time dobilo na uštedi memorije i vremena (objekti klase `cv::Mat` mogu biti naročito veliki tako da je ovaj korak ključan).

Unutar funkcije `IzdvojiKonture` prvo pozivamo OpenCV funkciju `cv::findContours` koja izdvaja konture sa proslijeđene slike i smješta ih vektor vektora tačaka. Ova funkcija je ključna za izdvajanje kontura i detalji njene implementacije unutar OpenCV ovdje neće biti objašnjeni. Nakon toga pozivamo funkciju `cv::drawContours` koja će da ucrta pronađene konture na izlaznoj rezultantskoj slici. Na kraju programa sačuvamo rezultantsku sliku na disk i rezultat ovoga je prikazan na slici 6.

Naizgled jednostavan algoritam, ali njegova implementacija zahtjeva malo naprednije znanje OpenCV-a, zbog određenih



Slika 6. Rezultat obrade slike i ekstrakcije kontura

problema koji se javljaju prilikom pripreme slike za ekstrakciju kontura (u ovom slučaju je to poznavanje morfološke operacije dilatacije).

Bitno je naglasiti da dati algoritam ne generiše samo vizuelni izgled konture dijagrama, već i njegov matematički opis. Autor ovog rada smatra da to pruža veću moć i fleksibilnost za korištenje i klasifikaciju Poincare dijagrama.

Da bi se klasifikovale ovako dobijene slike sa konturama, mišljenje autora ovog teksta je da se može tu iskoristiti *machine learning*. Svakako bi se mogla klasifikacija izvršiti i unutar OpenCV-a - ali to je mukotrpan posao koji bi zahtjevao kompleksniju geometrijsku analizu dobivenih oblika. Prijedlog za buduće unaprijeđenje ovog rada je priprema veće baze podataka različitih Poincare dijagrama, obrada slike i izdvajanje kontura kod takvih dijagrama i onda treniranje neuronske mreže da razlikuje patološke i nepatološke oblike. Pošto autor ovog teksta još uvijek ne zna to raditi, onda to nije implementirano u ovom seminarskom radu, ali autor se nada da će uskoro moći proširiti ovaj rad na opisani način.

LITERATURA

- [1] Fred Shaffer, Zachary M Meehan i Christopher L Zerr. "A critical review of ultra-short-term heart rate variability norms research". *Frontiers in neuroscience* 14 (2020.), str. 594880.
- [2] Przemyslaw Guzik i dr. "Heart rate asymmetry by Poincaré plots of RR intervals". (2006.). DOI: doi:10.1515/BMT.2006.054.
- [3] Satti R i dr. "The Application of the Extended Poincaré Plot in the Analysis of Physiological Variabilities". (2019.). DOI: doi:10.3389/fphys.2019.00116.
- [4] Heikki V Huikuri i dr. "Fractal correlation properties of RR interval dynamics and mortality in patients with depressed left ventricular function after an acute myocardial infarction". *Circulation* 101.1 (2000.), str. 47–53.
- [5] William S Cleveland. *Visualizing data*. Hobart press, 1993.

- [6] Parastoo Dehkordi i dr. "Pulse rate variability compared with heart rate variability in children with and without sleep disordered breathing". *2013 35th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*. IEEE. 2013., str. 6563–6566.
- [7] Mary A. Woo i dr. "Patterns of beat-to-beat heart rate variability in advanced heart failure". *American Heart Journal* 123.3 (1992.), str. 704–710. ISSN: 0002-8703. DOI: [https://doi.org/10.1016/0002-8703\(92\)90510-3](https://doi.org/10.1016/0002-8703(92)90510-3). URL: <https://www.sciencedirect.com/science/article/pii/0002870392905103>.
- [8] Berina Biberović. *Laboratorijska vježba 4 iz Biomedicinskih signala i sistema*. 2023.
- [9] P. W. Kamen i A. M. Tonkin. "Application of the Poincaré plot to heart rate variability: a new measure of functional status in heart failure". *Australian and New Zealand Journal of Medicine* 25.1 (1995.), str. 18–26. DOI: <https://doi.org/10.1111/j.1445-5994.1995.tb00573.x>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1445-5994.1995.tb00573.x>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1445-5994.1995.tb00573.x>.